Masterarbeit Exposé

Einleitung

Die Masterarbeit entwickelt ein verbessertes evolutionäres Neural Architecture Framework für pretrained Vision Transformers auf kleinen Datensätzen. Das Framework findet automatisch Pareto-optimale Architekturen, also Konfigurationen, die eine optimale Balance zwischen Genauigkeit und Parameterzahl erreichen. Der zentrale wissenschaftliche Beitrag ist die Antwort auf die Frage: Wann und warum lohnt sich der Einsatz von NAS für Vision Transformern gegenüber einfachem Fine-Tuning von CNN-Baselines?

Die Motivation hinter diesem Thema ist, dass sich Vision Transformer in der Verarbeitung von Bilddaten stark etabliert haben. Sie zeigen eine vergleichbare oder sogar überlegene Performance gegenüber klassischen CNN-Architekturen. Ein Problem von Vision Transformer zeigt jedoch die Dateneffizienz. Sie benötigen riesige Datensätze, da sie keine Locality Inductive Bias besitzen, um robuste Repräsentationen zu erlernen. In Datenarmen Szenarien zeigen sie daher nur beschränkte Generalisierungsfähigkeiten und starkes Overfitting. Es gibt in der Literatur jedoch bereits Ansätze, um diesen lokalen induktiven Bias zu erhöhen. Diese Ansätze wie Shifted Patch Tokenization oder Local Self-Attention zeigen, dass Vision Transformer auf kleine Datensätze angewendet werden können.

Um den Entwicklungsprozess zu optimieren kann Neural Architecture Search angewendet werden. NAS formuliert Architekturdesign als Optimierungsproblem über einen diskreten Suchraum und ist insbesondere für Transformer relevant, da kleine Architekturanpassungen große Auswirkungen haben können.

Der Titel der Arbeit lautet: „**Jenseits der Datenschwelle: Multi-Objective NAS zur Bewertung von Vision Transformers gegenüber CNN-Baselines auf kleinen Datensätzen**“.

Forschungsfragen

F1 – Ab welcher Datensatzgröße verliert ein NAS-optimierter Vision Transformer seinen Genauigkeitvorteil gegenüber CNN-Baselines bei vergleichbarer Parameteranzahl?

F2 – Unter welchen Bedingungen rechtfertigt der durch Neural Architecture Search erzielte Genauigkeitsgewinn den damit verbundenen Rechenaufwand gegenüber dem Fine-Tuning CNN-Baselines?

F3 - Inwiefern gelingt es einem NAS-optimierten Vision Transformer, bei reduzierter Parameteranzahl eine mit dem bisherigen State of the Art vergleichbare Klassifikationsgenauigkeit zu erzielen?

Methodik

Im Mittelpunkt der Arbeit steht die Entwicklung eines evolutionären Multi-Objective NAS-Frameworks, das pretrained ViTs auf kleinen Bilddatensätzen automatisch optimiert. Der Suchprozess kombiniert eine Pareto-basierte Selektion zur gleichzeitigen Optimierung von Genauigkeit und Modellgröße, Zero-Cost Proxies zur schnellen Vorfilterung von Architekturen ohne vollständiges Training, sowie Weight Inheritance zur Beschleunigung der Suche durch Wiederverwendung bereits trainierter Gewichte. Die gefundenen Architekturen werden anhand eines systematischen Evaluation-Frameworks bewertet,

das faire Vergleiche zwischen NAS-Ergebnissen und CNN-Baselines sicherstellt. Zentrale Bewertungsdimensionen sind Klassifikationsgenauigkeit, Parameteranzahl und Rechenaufwand der Suche in GPU-Stunden. Es wird eine zwei Stufen Bewertung genutzt, weil SPT/LSA strukturell mehr Parameter benötigen und sonst systematisch benachteiligt werde. Die Parameteranzahl und Rechenzeit bleiben Pareto-Ziele, jedoch werden LSA/SPT als separate Architekturklasse behandelt und auf ihrer eigenen Pareto-Front bewertet. Durch gezieltes Subsampling des Datensatzes wird empirisch untersucht ab welcher Datensatzgröße ein NAS-optimierter Vision Transformer die CNN-Baselines (ResNet, EfficientNet) übertrifft.
Als primärer Datensatz wird Food11 verwendet, ein öffentlich verfügbarer Bilddatensatz mit 11 Lebensmittelkategorien. Food11 eignet sich für diese Untersuchung, da er mit rund 16.000 Trainingsbildern in einem Größenbereich liegt, der die Grenze zwischen ausreichenden und unzureichenden Daten für Vision Transformers empirisch untersuchbar macht. Für die Schwellenwert-Analyse wird der Datensatz systematisch auf verschiedene Größen reduziert, um den Kreuzungspunkt zwischen ViT- und CNN-Genauigkeit zu bestimmen. Alle Daten sind öffentlich zugänglich und erfordern keine gesonderte Erhebung oder Anonymisierung.
Der wesentliche Ressourcenbedarf dieser Arbeit liegt im Bereich der Rechenkapazität. Evolutionäre NAS-Verfahren erfordern eine Vielzahl von Trainingsläufen. Trotz Zero-Cost Proxies zur Vorfilterung wird für die vollständigen Experimente Zugang zu den Hochschul GPUs benötigt. Weitere Mittel werden jedoch nicht benötigt.

Vorläufige Gliederung

1. Einleitung
    - 1.1 Motivation
    - 1.2 Forschungsfragen
    - 1.3 Beitrag der Arbeit
    - 1.4 Aufbau der Arbeit
2. Grundlagen
    - 2.1 Vision Transformers
    - 2.2 Neural Architecture Search
    - 2.3 Zero-Cost Proxies
    - 2.4 Multi-Objective Optimierung
    - 2.5 Efficient CNNs als Vergleichsklasse
3. Stand der Forschung
    - 3.1 ViTs auf kleinen Datensätzen
    - 3.2 Neural Architecture Search für Transformer Architekturen
    - 3.3 SOTA auf dem gewählten Datensatz
    - 3.4 Abgrenzung dieser Arbeit
4. Methodik
    - 4.1 Evaluations Framework
        - 4.1.1 Vergleich: NAS vs. CNN-Baselines
        - 4.1.2 Bewertung der Suchkostenrechtfertigung
        - 4.1.3 Generalisierbarkeit der gefundenen Architekturen
    - 4.2 Systemübersicht der NAS-Pipeline
    - 4.3 Suchraum Design
    - 4.4 Fitnessfunktion und Pareto-Dominanz
    - 4.5 Zero-Cost Proxy Integration
    - 4.6 Evolutionärer Algorithmus

        4.6.1 Mutationen und Crossover-Operatoren
    4.7 Weight Inheritance und Kompatibilitätsprüfung
    4.8 Evaluationsprotokoll
5. Evaluation und Ergebnisse
    5.1 Datensatz und Preprocessing
    5.2 Experimentelles Setup
    5.3 Baseline Ergebnisse
    5.4 NAS-Ergebnisse: Pareto Front
    5.5 Schwellenwertanalyse
        5.5.1 Accuracy Verläufe über Datensatzgröße
        5.5.2 Kreuzungspunkt ViT und CNN
        5.5.3 Statistische Absicherung
    5.6 Ablation Studis
    5.7 Suchkostenanalyse
6. Diskussion
    6.1 Beantwortung der Forschungsfragen
        6.1.1 Schwellenwert und CNN-Vergleich
        6.1.2 Pareto Effizienz gegenüber SOTA
        6.1.3 Rechtfertigung des NAS-Aufwands
    6.2 Analyse der gefundenen Architekturen
    6.3 Praktische Empfehlungen
    6.4 Einschränkungen und Limitierungen
7. Fazit
    7.1 Zusammenfassung der Beiträge
    7.2 Zukünftige Arbeiten

Zeitplan

Monat 1	**Foundation & Baselines**
Woche 1	Reproduzierbare Trainingspipeline
Woche 2	Datensatzpipline vollständig Food11 Pipeline Datensplitting Subsampling-Framework für Datenskalierung Evaluation Metrics definieren
Woche 3	CNN-Baseline Tabelle vorhanden MobileNetV3 ResNet18 EfficientNet-B0
Woche 4	ViT-Small Fine-Tuning Erste Vergleichsergebnisse Einleitung schreiben Kapitel 1 fertig
Monat 2	**NAS-Framework aufbauen**
Woche 5	Suchraum definieren Mutation Operatoren Architektur-Encoding Architekturrepräsentation stabil
Woche 6	Weight Inheritance

	Kompatibilitätsprüfung **Größtes Projektrisiko** Architekturwechsel ohne Abstürze
Woche 7	Multi-Objective Optimierung NSGA-II Elite Selektion Evolutionärer Zyklus lauffähig
Woche 8	Crossover Augmentierung als Suchparameter Smoke Tests Parallel: Kapitel 2 Grundlagen Meilenstein: Vollständiges NAS Framework
Monat 3	**Zero-Cost Proxies und NAS-Runs**
Woche 9	SynFlow NASWOT GradNorm Proxies Implementiert
Woche 10	Proxy-Korrelation analysieren Proxy-Auswahl begründet
Woche 11	NAS Runs mit Pareto Front Suchraum validieren
Woche 12	NAS Runs und Kapitel 3 fertig
Monat 4	**Experimente und Auswertung**
Woche 13	NAS-Runs mit mehreren Seeds
Woche 14	Datenskalierungsexperiment
Woche 15	Effizienzbewertung (Suchkosten, GPU-Stunden, Trainingszeit etc.)
Woche 16	Ablation Studies bsp. Ohne Zero-Proxies oder Weight Inheritance. Kapitel 4 schreiben
Monat 5	**Auswertung und Hauptschreiben**
Woche 17	Pareto-Fronten Visualisierungen Tabellen
Woche 18	Kapitel Ergebnisse
Woche 19	Diskussion / Forschungsfragen beantworten
Woche 20	Fazit Abstract Vollständiger Erstentwurf
Monat 6	**Finalisierung und Abgabe**
	Puffer und Nacharbeiten